

机器视觉期末复习资料

按考试复习要点与课件原话整理版

2026 年期末复习

使用说明

这份资料按《机器视觉》2026 年期末考试复习要点整理。考试范围为第 2 讲到第 15 讲，题型包括：单项选择题、多项选择题、填空题、简答题、计算题。

整理原则：

1. 概念、算法步骤、优缺点尽量使用课件原话或接近课件原话。
2. 公式用正式数学格式书写，便于背诵和计算。
3. 对容易考计算的内容，单独整理“考试计算模板”。
4. 对容易考简答的内容，整理成可以直接背的分点答案。

一、相机模型与图像（第 2 讲、第 6 讲相关基础）

1. 针孔相机模型

针孔相机模型用于描述三维空间点到二维图像平面的透视投影关系。

课件常用说法：

- 焦距 f ：成像平面到光心的距离。
- 光心 c ：相机的光学中心。
- 相机坐标系下，光心是坐标原点，基准点是成像平面内的坐标原点。
- 平行线在透视投影后会在图像中相交于消失点。

透视投影基本式：

$$x = \frac{fu}{w}, \quad y = \frac{fv}{w}$$

实际相机中，光感受器密度在 x 和 y 方向可能不同，因此使用不同焦距参数：

$$x = \frac{f_x u}{w}, \quad y = \frac{f_y v}{w}$$

2. 齐次坐标

课件原话要点：齐次坐标方便用矩阵乘法表示坐标之间的转换关系；成像平面的一个点，对应三维空间的一条射线。

二维点的齐次坐标：

$$(u, v) \Rightarrow \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \sim \begin{bmatrix} wu \\ wv \\ w \end{bmatrix}$$

三维点的齐次坐标：

$$(X, Y, Z) \Rightarrow \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \sim \begin{bmatrix} wX \\ wY \\ wZ \\ w \end{bmatrix}$$

齐次坐标转常规坐标：

$$\begin{bmatrix} x \\ y \\ w \end{bmatrix} \Rightarrow \left(\frac{x}{w}, \frac{y}{w} \right)$$

$$\begin{bmatrix} X \\ Y \\ Z \\ w \end{bmatrix} \Rightarrow \left(\frac{X}{w}, \frac{Y}{w}, \frac{Z}{w} \right)$$

3. 相机内部参数

相机内部参数描述相机自身成像结构，与相机在世界坐标系中的位置和方向无关。

相机内参矩阵为 3×3 上三角矩阵：

$$K = \begin{bmatrix} \phi_x & \gamma & \delta_x \\ 0 & \phi_y & \delta_y \\ 0 & 0 & 1 \end{bmatrix}$$

其中：

- ϕ_x, ϕ_y ：焦距参数，包含焦距和光感受器密度的影响。
- δ_x, δ_y ：图像平面中心点相对于左上角的平移量，也可理解为主点偏移。
- γ ：斜切参数，表示投影平面坐标轴不垂直的情况。

齐次坐标矩阵形式：

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} \phi_x & \gamma & \delta_x \\ 0 & \phi_y & \delta_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ w \end{bmatrix}$$

即：

$$x = \phi_x u + \gamma v + \delta_x w$$

$$y = \phi_y v + \delta_y w$$

$$z = w$$

4. 相机外部参数

相机外部参数描述相机相对于世界坐标系的位置和方向。

- 旋转矩阵 R ：与相机方向相关。

- 平移向量 T ：相机位置相对于世界坐标系原点的平移量。

世界坐标系中的三维点映射到图像中：

$$\begin{bmatrix} wu \\ wv \\ w \end{bmatrix} = K[R|T] \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

其中：

$$P = K[R|T]$$

P 称为投影矩阵。

考试易错点：内参和相机结构有关；外参和相机结构无关。题目若问“和相机结构无关的参数”，一般选 R, T 。

5. 归一化相机

归一化相机是指当相机内参 K 已知时，切换到新的图像坐标系，使内参矩阵变成单位矩阵。

归一化后：

$$\tilde{x} = K^{-1}x$$

新的投影矩阵为：

$$\tilde{P} = [R|T]$$

课件原话要点：归一化后，图像与相机内部参数无关，仅取决于相机的外部参数；归一化相机以相机位置为坐标原点，焦距为 1，图像中心坐标定义为光心。

6. 图像与颜色空间

图像在计算机中表示为矩阵形式，矩阵中的每一个元素对应一个像素。彩色图像通常有红绿蓝三个通道（RGB）。

常见颜色空间：

常见颜色空间：

- 红绿蓝颜色空间（RGB）：光学三原色为红、绿、蓝；三原色同时相加为白色。常考点：三个通道相关性强，不符合人对颜色的直观理解。
- 色调-饱和度-明度颜色空间（HSV）：更接近人对颜色的直观理解。常考点：H 表示色调，S 表示饱和度，V 表示明度。
- 亮度-色度颜色空间（YCbCr）：适用于数字电视系统，计算快。常考点：Y 表示亮度，Cb 和 Cr 表示蓝色、红色相对绿色的分量。

色调-饱和度-明度颜色空间（HSV）中：

- H 表示色调，取值 到 ；红色，绿色，蓝色。
- S 表示饱和度，即颜色接近光谱色的程度，取值 到 。
- V 表示明度，即颜色的明亮程度，取值 到 。

二、图像处理（第 3 讲）

1. 点处理

点处理是指对每个像素的灰度值单独进行变换，空间信息被忽略。

一般形式：

$$g(x, y) = t(f(x, y))$$

也可写为：

$$I' = t(I)$$

2. 伽马校正

课件中伽马变换用于图像增强，通过灰度变换函数增强图像对比度。

公式：

$$y = f(x) = x^\gamma$$

背诵要点：

- $\gamma < 1$ ：低灰度区域被拉亮，图像整体变亮。
- $\gamma > 1$ ：低灰度区域被压暗，图像整体变暗。

3. 图像直方图

图像直方图表示不同灰度值出现的概率。

灰度值 i 的概率：

$$p_i = \frac{n_i}{n}$$

其中 n_i 是灰度值为 i 的像素个数， n 是图像中所有像素的个数。

课件原话要点：灰度分布范围越广，对比度越高。

4. 直方图均衡化

直方图均衡化的目的：改善图像对比度，使累积直方图从左下到右上更接近均匀增长。

累积分布函数：

$$t(i) = \sum_{j=0}^i p_j$$

灰度映射：

$$y_i = f(i) = (L - 1)t(i)$$

其中 L 是灰度级数。

背诵句：直方图均衡化利用累积直方图进行灰度映射，使灰度分布更均匀，从而提高图像对比度。

5. 窗宽窗位

医学图像具有较宽范围的灰度值，例如 CT/MRI 中灰度可能在 $(-2000, 2000)$ 之间。为了在屏幕上显示，需要将其映射到 0 到 255 或 0 到 1。

窗位 L 表示显示范围中心，窗宽 W 表示显示范围宽度。

可显示灰度范围为：

$$\left[L - \frac{W}{2}, L + \frac{W}{2} \right]$$

例如窗宽 $W = 500$ 、窗位 $L = 100$ ，则显示范围为：

$$\left[100 - \frac{500}{2}, 100 + \frac{500}{2} \right] = [-150, 350]$$

课件原话要点：如果窗宽为 0，得到的将是二值图像。

6. 邻域处理与滤波

邻域处理根据一个像素周围邻域中的像素值计算输出像素值。

线性滤波或相关运算：

$$h[m, n] = \sum_{k=-u}^u \sum_{l=-v}^v f[k, l] I[m+k, n+l]$$

其中 f 称为滤波核，也可称为模板或滤波器（kernel / mask / filter，均为专业术语）。

卷积与自相关的区别：卷积在应用到图像前需要将滤波核在水平和垂直方向翻转：

$$h[m, n] = \sum_{k=-u}^u \sum_{l=-v}^v f[-k, -l] I[m+k, n+l]$$

课件原话要点：如果 f 对称，则卷积和自相关相同；实际中二者常常不严格区分，卷积神经网络（CNN）中很多实现实际使用的是互相关（cross-correlation）。

7. 均值滤波、中值滤波、高斯滤波

三种常见滤波方法：

- 均值滤波：将每个像素替换为其邻域平均值，实现平滑效果。常考点：图像会变模糊，边缘也会模糊。
- 中值滤波：将窗口中心像素替换为该窗口内灰度值的中位数。常考点：非线性滤波；能更好处理椒盐噪声；可以保留边缘。
- 高斯滤波：根据距离远近对邻域像素赋予高斯权重。常考点：低通滤波；去除高频成分；图像更平滑。

高斯滤波常考性质：

1. 从图像中去除高频成分，即低通滤波。
2. 高斯函数与高斯函数卷积后仍然是高斯函数。
3. 高斯滤波器具有可分离性，即二维高斯核可分解为两个一维高斯核。

可分离性的计算量优势：

- 直接二维卷积：约 $MNPQ$ 次乘加。
- 可分离二维卷积：约 $MN(P+Q)$ 次乘加。
- 加速比：

$$\frac{PQ}{P+Q}$$

8. 频域变换

傅里叶分析的基本思想：任意一维函数都可以表示为不同频率正弦和余弦函数的加权和。

傅里叶级数形式：

$$\sum_{n=1}^{\infty} a_n \cos(nt) + b_n \sin(nt)$$

幅值和相位形式：

$$\frac{a_0}{2} + \sum_{n=1}^N a_n \sin(nx + \phi_n)$$

其中 $a_0/2$ 表示信号一个周期内的平均值。

卷积定理：空间域卷积等价于频率域乘法。

$$\mathcal{F}[g * h] = \mathcal{F}[g] \mathcal{F}[h]$$

$$g * h = \mathcal{F}^{-1}(\mathcal{F}[g] \mathcal{F}[h])$$

高频与低频：

- 高频：对应边缘、细节、快速变化。
- 低频：对应平滑区域、整体结构、缓慢变化。

三、特征检测（第 4 讲）

1. Harris 角点检测

角点检测的目标：找到图像中具有明显局部结构、容易在不同图像中匹配的关键点。

2. 自相关函数

课件原话要点：对于给定偏移量 (u, v) ，计算像素 (x, y) 和附近像素 $(x + u, y + v)$ 的差值平方，并在所有像素上加权求和。

$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

其中 w 是窗口函数，可以是窗口内为 1、窗口外为 0，也可以是高斯窗口。

局部二次近似：

$$E(u, v) \approx \begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix}$$

二阶矩矩阵：

$$M = \sum_{x, y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

3. 用特征值判断角点、边缘、平坦区域

设 M 的两个特征值为 λ_1, λ_2 。

用特征值判断图像区域：

- λ_1, λ_2 都很小：平坦区域， E 在所有方向几乎不变。
- 一个特征值大，另一个接近 0：边缘，沿一个方向变化快，另一个方向变化慢。
- λ_1, λ_2 都较大且接近：角点， E 在所有方向都明显增大。

Harris 角点分数：

$$C = \det(M) - \alpha \text{trace}(M)^2$$

等价写法：

$$C = \lambda_1 \lambda_2 - \alpha (\lambda_1 + \lambda_2)^2$$

其中 α 通常取 0.04 到 0.06。

4. Harris 角点检测步骤

可以直接背：

1. 对每个窗口计算二阶矩矩阵 M ，得到角点响应分数 C 。
2. 设置阈值，保留 $C > \text{threshold}$ 的像素。
3. 进行非极大值抑制，保留局部最大值点。

5. Canny 边缘检测

边缘是图像强度函数快速变化的位置，对应图像中的高频信息。

Canny 边缘检测的优点：

- 高信噪比。
- 高定位精度。

- 高连续性。

Canny 算法步骤（按课件原话背）：

1. 使用高斯函数的一阶导数对图像滤波，即在 x 和 y 方向上分别进行高斯差分滤波。
2. 计算梯度幅值和梯度方向，即计算各像素处梯度的大小与方向。
3. 进行非最大值抑制，即根据梯度方向抑制非局部最大值，使多像素宽的边缘变成单像素宽。
4. 进行滞后阈值处理与边缘连接，即通过两个阈值区分强边缘和弱边缘，并将可通过弱边缘连接的强边缘连接起来。

梯度幅值：

$$G = \sqrt{G_x^2 + G_y^2}$$

梯度方向：

$$\theta = \text{atan2}(G_y, G_x)$$

滞后阈值法：

- $G > t_{high}$: 强边缘。
- $G < t_{low}$: 噪声。
- $t_{low} \leq G \leq t_{high}$: 弱边缘。
- 从强边缘出发，沿弱边缘继续连接。

6. 霍夫变换

霍夫变换是一种投票技术，用于检测直线或其他参数化曲线。

直线普通表示 $y = mx + b$ 的问题：

- m, b 可能取无穷值。
- 垂直线无法表示。

因此课件采用极坐标表示直线：

$$d = x \cos \theta + y \sin \theta$$

其中：

- d : 直线到原点的垂直距离。
- θ : 垂线与 x 轴的夹角。

对应关系：

- 图像空间中的一条直线，对应霍夫空间中的一个点。
- 图像空间中的一个点，对应霍夫空间中的一条正弦曲线。
- 多个共线点在霍夫空间中的曲线交于同一个峰值点。

霍夫变换算法步骤：

1. 初始化累加器 $H[d, \theta] = 0$ 。
2. 对每个边缘点 (x, y) ，遍历 θ ，计算 $d = x\cos\theta + y\sin\theta$ 。
3. 对相应的 $H[d, \theta]$ 加 1。
4. 找到 $H[d, \theta]$ 最大的位置，对应图像中最显著的直线。

四、特征描述与图像对齐（第 5 讲）

1. 局部特征的三个主要组成部分

课件原话式总结：

1. 特征检测：找到一组有区分性的关键点。
2. 特征描述：在每个兴趣点周围提取特征描述子，并表示为向量。
3. 特征匹配：计算特征向量之间的距离，寻找两幅图像中的对应点。

2. SIFT 特征描述

尺度不变特征变换（SIFT）：一种广泛使用的局部特征描述方法。

课件给出的优点：

- 具有方向不变性。
- 具有尺度不变性。
- 对光照变化不敏感。

SIFT 的基本思想：

1. 在位置-尺度空间中寻找局部极大值，得到 (x, y, s) 。
2. 计算关键点邻域内的梯度方向直方图。
3. 选择主导方向 θ ，将局部区域旋转到固定方向，实现旋转不变性。
4. 在 16×16 窗口中划分为 4×4 个小区域，每个小区域统计 8 个方向的梯度直方图。
5. 得到 $4 \times 4 \times 8 = 128$ 维特征向量。
6. 对向量进行归一化，增强对亮度变化的鲁棒性。

对光照变化不敏感的原因：

- 由于在梯度空间中工作，所以对 这种亮度平移较鲁棒。
- 由于对特征向量进行归一化，所以对 这种亮度缩放较鲁棒。

3. 特征匹配

从两幅图像中找出最相似的特征点，通常根据特征描述子之间的相似性。

常用相似性度量：

欧氏距离：

$$d(x_1, x_2) = \sqrt{\sum_i (x_{1i} - x_{2i})^2}$$

余弦相似度：

$$\cos(x_1, x_2) = \frac{x_1^T x_2}{\|x_1\| \|x_2\|}$$

4. 图像对齐

图像对齐分为两类：

两类图像对齐方法：

- 基于像素的直接对齐：寻找使大多数像素一致的对齐方式。特点：费时，对颜色变化敏感。
- 基于特征的对齐：寻找使提取出的特征一致的对齐方式。特点：更加高效，对颜色变化鲁棒。

5. 常见二维空间变换

平移：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

旋转：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

仿射变换：

$$\begin{bmatrix} x' \\ y' \\ w \end{bmatrix} = \begin{bmatrix} a & b & c \\ d & e & f \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ w \end{bmatrix}$$

课件原话要点：仿射变换由线性变换和平移组成；直线的平行关系可以保留；仿射变换矩阵有 6 个参数。

投影变换：

$$\begin{bmatrix} x' \\ y' \\ w' \end{bmatrix} = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix} \begin{bmatrix} x \\ y \\ w \end{bmatrix}$$

课件原话要点：投影变换中，直线的平行关系可能丢失；投影变换矩阵有 9 个参数，但整体尺度不影响变换，通常有 8 个自由度。

6. 仿射变换参数拟合

若已知对应点 $(x_i, y_i) \leftrightarrow (x'_i, y'_i)$ ，仿射变换可写为：

$$\begin{bmatrix} x'_i \\ y'_i \end{bmatrix} = \begin{bmatrix} m_1 & m_2 \\ m_3 & m_4 \end{bmatrix} \begin{bmatrix} x_i \\ y_i \end{bmatrix} + \begin{bmatrix} t_1 \\ t_2 \end{bmatrix}$$

展开为线性方程：

$$\begin{bmatrix} x_i & y_i & 0 & 0 & 1 & 0 \\ 0 & 0 & x_i & y_i & 0 & 1 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ m_3 \\ m_4 \\ t_1 \\ t_2 \end{bmatrix} = \begin{bmatrix} x'_i \\ y'_i \end{bmatrix}$$

多组点可构成超定方程，使用最小二乘法求解。

7. RANSAC

随机抽样一致性算法（RANSAC）：用于在存在离群点时稳健估计模型参数。

课件原话要点：为了避免离群点影响参数估计，需要寻找内点，并只用内点重新估计参数。

RANSAC 步骤：

1. 随机选择一组种子点作为估计变换的基础。
2. 根据选中的点组计算变换参数。
3. 寻找符合该变换的内点。
4. 如果内点数量足够多，则用所有内点重新进行最小二乘估计。
5. 保留内点数量最多的变换。

8. 全景图拼接简答模板

题目：同一静态场景中，相机位置和方向稍微调整，调整前后拍摄两幅照片 A 和 B，想合成一幅全景图，简述步骤。

可背答案：

1. 特征点检测：可利用 Harris 角点检测实现，找到具有区分性的关键点。
2. 特征点描述：可利用 SIFT 描述算子，提取具有尺度不变性、旋转不变性、对光照变化不敏感的局部特征。
3. 特征匹配：计算特征向量相似性，如欧氏距离或余弦相似度，找到两幅图像中的匹配点。
4. 空间变换参数拟合：利用 RANSAC 去除错误匹配点，并估计仿射或投影变换参数。
5. 图像对齐与融合：根据估计出的空间变换参数，将一幅图像变换到另一幅图像坐标系下，并进行融合得到全景图。

五、图像分割（第7讲、第8讲）

1. 图像分割概念

课件原话式定义：图像分割是将图像划分为多个区域的过程，这些区域可以是不同物体或超像素；目标是简化图像表示，使图像更有意义、更容易分析；有助于检测物体和边界。

也可以背成：图像分割可看作像素级分类，或寻找区域轮廓的过程。

二值分割：获得前景区域和背景区域。

2. 基于阈值的分割

基于阈值的分割只考虑像素值，简单、容易实现，常利用直方图形状自动确定阈值。

全局阈值：用一个阈值 T 将图像分为前景和背景。

迭代寻找全局阈值的步骤：

1. 选择初始阈值。
2. 定义 $f(x, y) > T_0$ 为背景， $f(x, y) < T_0$ 为前景。
3. 计算背景均值 μ_b 和前景均值 μ_f 。
4. 设置新的阈值：

$$T_i = \frac{\mu_b + \mu_f}{2}$$

5. 重复直到 $T_i = T_{i-1}$ 。

全局阈值适用情况：前景和背景灰度值差异明显。

全局阈值局限性：前景和背景灰度接近，或者亮度不均匀时效果不好。

局部阈值：将图像划分为不重叠小区域，每个局部区域内光照近似均匀，再分别求阈值。

3. Otsu 大津算法

大津算法（Otsu）是一种最佳阈值方法。

课件原话要点：通过最小化类内方差确定阈值，等价于最大化类间方差。

类内方差：

$$\sigma_w^2(t) = \omega_1(t)\sigma_1^2(t) + \omega_2(t)\sigma_2^2(t)$$

类间方差：

$$\sigma_b^2(t) = \omega_1(t)\omega_2(t)[\mu_1(t) - \mu_2(t)]^2$$

选择使类内方差最小，或类间方差最大的阈值。

4. 分水岭算法

课件原话式背诵：把灰度图像看作一个地势图，亮度值当作高度值；让水从每个谷底上升；当两个谷中的水相遇时，建立堤坝或分水岭；这些分水岭定义了不同区域之间的边界。

注意：直接在灰度图上使用分水岭容易过分割，常先进行平滑或在距离变换图上使用。

5. 基于聚类的分割

聚类是无监督数据分析。

课件原话要点：聚类的目标是找到若干组对象，使同一组内的对象相似，不同组之间的对象不同。

目标：簇内距离最小化，簇间距离最大化。

K-means 分割步骤：

1. 选择聚类数 K 。
2. 为每个像素选择特征向量，例如颜色、纹理、位置或其组合。
3. 定义特征向量之间的相似性度量，通常使用欧氏距离。
4. 应用 K-均值算法。
5. 对结果进行后处理。

K-means 核心过程：

- 每个点分配给最近的聚类中心。
- 重新计算每个簇的中心。
- 交替更新像素所属类别和聚类中心，直到收敛。

6. 活动轮廓模型

活动轮廓将分割看作曲线变形过程。定义一个能量函数，并通过最小化能量得到分割轮廓。

课件原话要点：

- 把分割看作曲线的变形过程。
- 为轮廓定义能量函数，并通过最小化能量得到分割结果。
- 可以得到平滑的分割轮廓。
- 典型方法包括蛇形模型和水平集模型。

7. Snake 蛇形模型

Snake 将轮廓表示为一组二维控制点或顶点，通过移动控制点实现轮廓变化。

总能量由内部能量和外部能量组成：

$$E_{snake} = E_{internal} + E_{external}$$

内部能量：鼓励轮廓满足先验形状偏好，例如平滑性、弹性和低曲率。

外部能量：鼓励轮廓贴合图像结构，例如边缘。

一种外部能量定义为梯度幅值的负值：

$$E_{external} = - (G_x(I)^2 + G_y(I)^2)$$

含义：梯度大的地方能量低，轮廓更倾向于落在边缘上。

内部能量常包括：

- 弹性约束。
- 曲率约束。

Snake 优点：

- 复杂度低。
- 易于引入先验知识。
- 可处理开放结构和闭合结构。

Snake 缺点：

- 对初始轮廓敏感。
- 不能改变形状的拓扑结构。
- 参数空间和采样规则会影响结果。

8. 水平集模型

水平集方法将曲线表示为隐式曲面。

设 $\phi(x, y)$ 是一个曲面，则零水平集：

$$\phi(x, y) = 0$$

对应二维空间中的一条曲线。

水平集常用带符号距离函数表示：

$$\phi(x) = \begin{cases} -\text{dist}(x, C), & x \text{ inside } C \\ 0, & x \in C \\ \text{dist}(x, C), & x \text{ outside } C \end{cases}$$

演化形式：

$$\phi_{t+1} = \phi_t + \lambda \frac{\partial \phi}{\partial t}$$

速度函数可根据梯度或曲率定义。

水平集优点：

- 所有计算在固定网格上进行，不需要重新参数化。
- 可自然处理拓扑结构变化。

9. Snake 与水平集区别

蛇形模型与水平集模型对比：

- 表示方式：蛇形模型用一组离散控制点；水平集模型用隐式曲面上的零水平集。
- 拓扑变化：蛇形模型不允许改变拓扑结构；水平集模型可自然处理拓扑结构变化。
- 初始轮廓：蛇形模型对初始轮廓敏感；水平集模型相对更灵活。
- 计算方式：蛇形模型通过控制点移动；水平集模型在固定网格上演化函数。

10. Chan-Vese 模型

陈-维塞模型（Chan-Vese）是基于区域的水平集模型，也称为无边缘活动轮廓模型。

课件原话要点：边缘型水平集在边界弱时效果不好，因为停止函数在边缘处不一定为零；陈-维塞模型定义基于区域的能量函数，不需要边缘检测。

陈-维塞模型思想：使轮廓内部区域和外部区域各自尽量灰度一致，即类内方差最小化。

常见能量项包括：

- 轮廓长度项。
- 区域面积项。
- 内部区域方差。
- 外部区域方差。

11. 图割 Graph Cut

图的定义：图是由顶点和边组成的结构。图像也可以看作图：每个像素是一个顶点，边表示像素之间的关系。

图割基本思想：

- 额外加入源点 s 和汇点 t ，分别代表两个类别。
- 图中的边分为两种：
 - 邻接边（ n -link）：相邻两个像素之间的权重。
 - 终端边（ t -link）：某个像素与源点 或汇点 之间的连接权重。
- 一个割是图中一部分边的集合，将图分成两个不相连部分，即得到分割结果。

最小割：代价之和最小的割，作为分割边界。

课件原话要点：最小代价的源点-汇点割可以在多项式时间内求出；这个问题也称为最大流问题。

权重设置：

- 邻接边：一般相邻像素间灰度差异越大，代价越小，因为更可能是边界。
- 终端边：表示像素属于前景或背景的代价。

若 p 被指定为前景：

$$S_p = K, \quad T_p = 0$$

若 p 被指定为背景：

$$S_p = 0, \quad T_p = K$$

其他像素可根据灰度概率设置：

$$S_p = -\ln P(I_p|T), \quad T_p = -\ln P(I_p|S)$$

12. 形态学运算

形态学运算是一种简单且广泛使用的后处理方法，使分割结果更少噪声、更平滑，也可用于提取目标中心线。

基本操作：膨胀、腐蚀、开运算、闭运算。

腐蚀：逻辑“与”操作。若图像局部范围内与结构单元的前景模式全部匹配，则输出中心像素为 1，否则为 0。作用：去掉图像中小的不连通区域，使前景变小。

膨胀：逻辑“或”操作。把结构元素放在每个前景像素处，用 OR 操作扩展前景。作用：填充小空洞，使前景变大。

开运算：先腐蚀后膨胀。

$$A \circ B = (A \ominus B) \oplus B$$

作用：打开物体之间的小间隙，去除小物体或细小连接。

闭运算：先膨胀后腐蚀。

$$A \bullet B = (A \oplus B) \ominus B$$

作用：关闭小孔洞或小间隙，填充前景中的小洞。

六、多视图几何与立体视觉（第 6 讲）

1. 多视图几何的目标

课件原话式总结：多视图重建是从两张或多张图像中重建形状；为了进行三角测量，需要估计相机视角；极线几何告诉我们，对应点不需要在整幅图像中搜索，而只需要在某条极线上搜索。

2. 相机校正

相机校正基本思想：已知一组三维世界坐标点对应的图像点，求相机矩阵 P ，再进一步分解得到内参和外参。

投影矩阵：

$$\begin{bmatrix} wu \\ wv \\ w \end{bmatrix} = P \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} = K[R|T] \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

P 有 12 个元素，但整体尺度不影响结果，所以有 11 个自由度。每一组 3D-2D 对应点提供两个独立约束，因此通常需要 6 组以上对应点，并用最小二乘估计 P 。

基于 P 估计内参 K ：利用 K 是上三角矩阵、 R 是正交矩阵这一先验，对 P 左侧 3×3 部分进行矩阵分解并归一化。

3. 极线几何

极线几何描述两幅图像中对应点之间的约束关系。

课件原话要点：

- 对于右图中的点 p_2 ，其在左图中的对应点 p_1 必定位于左图中某一条极线上。
- 对于某个三维点 P ，存在一对对应极线 l_1, l_2 。
- P, l_1, l_2, C_1, C_2 位于同一个极平面。
- 对应点只能位于对应极线上，因此可减少匹配搜索范围。

4. 本征矩阵 (Essential Matrix)

对于归一化相机，两幅图像中的对应点满足：

$$x_2^T E x_1 = 0$$

其中 E 是本征矩阵。

给定相机间旋转 R 和平移 T ：

$$E = [T]_{\times} R$$

含义： E 完全描述归一化相机中对应极线关系。

给定 x_1 ，右图中的极线为：

$$l_2 = E x_1$$

对应点 x_2 满足：

$$x_2^T l_2 = 0$$

5. 叉乘矩阵

向量：

$$a = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix}$$

标准叉乘矩阵常写为：

$$[a]_{\times} = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix}$$

使得：

$$a \times b = [a]_{\times} b$$

考试提醒：如果题目给出了特定的叉乘矩阵定义，必须按题目给出的矩阵直接计算，不要自行改符号。

6. 基础矩阵 (Fundamental Matrix)

本征矩阵假设图像坐标已经归一化；未归一化相机使用基础矩阵 F 。

归一化坐标：

$$\tilde{x} = K^{-1}x$$

由：

$$\tilde{x}_2^T E \tilde{x}_1 = 0$$

得到：

$$x_2^T K^{-T} E K^{-1} x_1 = 0$$

定义：

$$F = K^{-T} E K^{-1}$$

因此：

$$x_2^T F x_1 = 0$$

基础矩阵性质：

- 如果 F 是基础矩阵，那么 kF 也是基础矩阵。
- F 的秩为 2。
- F 有 7 个自由度。

本征矩阵与基础矩阵对比：

本征矩阵与基础矩阵对比：

- 本征矩阵 E ：用于归一化/已标定相机；极线约束为 $x_2^T E x_1 = 0$ ；公式为 $E = [T]_{\times} R$ 。
- 基础矩阵 F ：用于未归一化/未标定相机；极线约束为 $x_2^T F x_1 = 0$ ；公式为 $F = K^{-T} E K^{-1}$ 。

7. 八点算法

求基础矩阵或本征矩阵时，若有 $N \geq 8$ 组匹配点，每组匹配点提供一个线性方程。

设：

$$x_i = (x_i, y_i, z_i)^T, \quad \bar{x}_i = (\bar{x}_i, \bar{y}_i, \bar{z}_i)^T$$

对应点满足：

$$\bar{x}_i^T F x_i = 0$$

把 F 的 9 个元素按列或按行展开为向量 f ，得到：

$$A f = 0$$

因为尺度任意，8 组点足以确定 3×3 矩阵的元素；实际中用更多点可做最小二乘估计。

8. 三角测量

三角测量目标：已知两个相机的投影矩阵 P_1, P_2 和一对匹配点 x_1, x_2 ，求三维点 X 。

投影关系：

$$x_1 = P_1 X, \quad x_2 = P_2 X$$

考试计算常用方法：把三维点设为 $X = (x, y, z, 1)^T$ ，再分别代入两个投影矩阵，使用齐次比例因子 w_1, w_2 建方程，联立求解 x, y, z 。

七、图像识别与传统目标检测（第 9 讲、第 10 讲）

1. 图像识别基本框架

图像识别通常是分类问题。

基本流程：

输入图像→特征提取→分类器→识别结果

有监督学习：训练样本带有对应输出或标签。

训练集：

$$\{(x_1, y_1), \dots, (x_N, y_N)\}$$

预测函数：

$$y = f(x, w)$$

训练过程相当于估计函数参数 w ，使训练集上的预测误差尽可能小：

$$w^* = \operatorname{argmin}_w \sum_i L(y_i, f(x_i, w))$$

2. 线性分类器

二维二分类线性分类器的决策边界：

$$w_0 + w_1 x_1 + w_2 x_2 = 0$$

推广到高维：

$$f(X, W) = u(W^T X)$$

课件原话要点：基于特征线性组合进行决策的分类器称为线性分类器。

3. 欠拟合与过拟合

欠拟合：决策边界过于简单，无法很好地区分样本；分类器的假设空间表达能力不够。

过拟合：模型在训练数据上表现很好，但在测试数据上表现差。原因包括训练数据有限、复杂模型参数过多、模型过度适应随机噪声。

判断过拟合：训练误差不能很好估计模型在未见数据上的表现，因此将训练数据分为训练集和验证集，使用验证集估计泛化误差。

注意：验证集不是测试集。

4. 分类评价指标

混淆矩阵：

混淆矩阵记忆：

- 预测正类、实际正类：TP。
- 预测正类、实际负类：FP。
- 预测负类、实际正类：FN。
- 预测负类、实际负类：TN。

准确率：

$$Acc = \frac{TP + TN}{TP + FP + TN + FN}$$

精确率 精确率：

$$Precision = \frac{TP}{TP + FP}$$

含义：被选中的样本中，有多少是真正相关的。

召回率 召回率：

$$Recall = \frac{TP}{TP + FN}$$

含义：所有真正相关的样本中，有多少被选中了。

F1：精确率和召回率的加权平均，常用形式：

$$F1 = \frac{2PR}{P + R}$$

受试者工作特征曲线（ROC）：显示真正率（TPR）和假正率（FPR）之间的权衡关系。

曲线下面积（AUC）：受试者工作特征曲线下面积，取值范围 到 。

5. 特征袋模型（Bag-of-Features）

目标：将图像转化为固定长度的特征向量，用于分类。

课件原话式总结：特征袋模型把图像表示为一组视觉词汇出现频率的直方图。

构建步骤：

1. 特征提取：在规则网格或兴趣区域提取局部特征。
2. 学习视觉词汇：用聚类学习视觉词汇或字典。
3. 视觉词汇量化：将局部特征量化到最近视觉词。
4. 图像表示：用视觉词频直方图表示图像。

优点：

- 对几何变化、形变、视角变化较灵活。

- 对图像内容给出紧凑总结。
- 为局部特征集合提供固定维度向量表示。

缺点：

- 忽略图像中物体的位置关系和结构信息。
- 前景和背景混在一起。
- 最优词典形成方式不明确。

空间金字塔：在不同空间划分层级中分别统计直方图，是特征袋模型的扩展，可部分保留空间布局信息。

6. 目标检测基本流程

目标检测：在图像中找到目标实例的边界框。

一般方法步骤：

1. 指定目标模型。
2. 产生候选假设，例如滑动窗口或区域提议。
3. 对候选区域进行打分。
4. 检测解析，常用非极大值抑制去除重叠检测。

7. IoU、精确率、召回率、AP、mAP

交并比（IoU）：预测框与真实框交集面积和并集面积的比值。

$$IoU = \frac{|B_p \cap B_g|}{|B_p \cup B_g|}$$

若 $IoU \geq t$ ，预测框可认为是真阳性；若 $IoU < t$ ，则是假阳性。

检测中的精确率和召回率：

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

平均精度（AP）：考虑不同分类阈值下所有精确率和召回率的组合，把精确率-召回率曲线综合成一个指标。可以理解为该曲线下面积或不同召回率位置下精确率的加权平均。

平均精度均值（mAP）：常见平均方式包括：

1. 固定交并比阈值下，对所有类别的平均精度取平均。
2. 在多个交并比阈值下分别计算平均精度，再对交并比阈值和类别共同取平均。

考试要注意：平均精度不是“不同交并比下的均值”；平均精度通常先在固定交并比阈值和固定类别上，由精确率-召回率曲线得到。平均精度均值才是对多个平均精度再取平均。

8. Dalal-Triggs 行人检测

Dalal-Triggs 方法：方向梯度直方图（HOG）+ 线性支持向量机（线性支持向量机）。

步骤：

1. 在每个位置和尺度上提取固定大小窗口。
2. 在每个窗口中计算方向梯度直方图特征。
3. 用线性支持向量机分类器对窗口打分。
4. 进行非极大值抑制，去除重叠且分数较低的检测框。

方向梯度直方图（HOG）：统计局部区域中不同方向梯度的分布。

HOG 特征维度计算常考例子：

- 检测窗口： 64×128 。
- 单元格大小：，因此单元格数为。
- 块大小：单元格 s ，即。
- 块滑动步长为 1 个单元格，因此块数：

$$(8 - 2 + 1) \times (16 - 2 + 1) = 7 \times 15$$

- 每个单元格有 9 维方向直方图，每个块有 维。

整个感兴趣区域特征维度：

$$7 \times 15 \times 9 \times 4 = 3780$$

方向梯度直方图归一化作用：使特征描述对光照变化不敏感。

9. Viola-Jones 人脸检测

Viola-Jones 是实时人脸检测的经典方法。

关键思想：

1. 积分图：用于快速计算类 Haar 特征。
2. 提升算法：用 AdaBoost 选择少量有效特征并训练强分类器。
3. 注意力级联：用级联分类器快速拒绝非人脸窗口。

积分图定义：对每个像素 (x, y) ，计算其左上方所有像素和。

矩形区域和可由四个角的积分图值快速计算：

$$sum = A - B - C + D$$

任意大小矩形区域只需要三次加减运算。

类 Haar 特征：不同矩形区域灰度差的差值。

$$Value = \sum(\text{白色区域}) - \sum(\text{黑色区域})$$

Viola-Jones 常考搭配：基于积分图类 Haar 特征 + AdaBoost 分类器。

八、深度学习与卷积神经网络图像分类（第 11 讲、第 12 讲）

1. 深度学习与传统机器学习区别

课件原话式总结：传统机器学习先人工提取特征，再使用分类器；深度学习尝试通过多层结构自动学习多层次表示，即自动特征学习。

深度学习成功原因：

- 大量数据。
- 计算设备。
- 深层网络。

2. 人工神经网络

神经网络由输入层、隐藏层、输出层组成。训练人工神经网络（ANN）意味着学习神经元的权重。

BP 神经网络通过误差后向传播和梯度下降调节参数：

$$w_j^{new} = w_j^{old} - \lambda \frac{\partial Loss}{\partial w_j}$$

3. 卷积神经网络（CNN）

卷积神经网络（CNN）基本结构：卷积层、池化层、全连接层重复组合。

卷积层作用：通过卷积核提取特征。

特点：

- 共享权重。
- 位移不变性或平移等变性相关能力。
- 参数可通过训练自动学习。

卷积层输出大小：

$$W' = \frac{W - F + 2P}{S} + 1$$

其中：

- W ：输入大小。
- F ：卷积核大小。
- P ：填充（padding）。
- S ：步长（stride）。

多通道卷积参数量：输入通道 C_{in} ，输出通道 C_{out} ，卷积核大小 $K \times K$ 。

$$N_p = K \times K \times C_{in} \times C_{out}$$

若考虑偏置项：

$$N_p = K^2 C_{in} C_{out} + C_{out}$$

分组卷积：将输入通道分为 G 个组，每组分别卷积，结果拼接，参数量减少约 G 倍。

深度可分离卷积：分组数等于输入通道数，通常与 卷积结合，用于轻量级卷积神经网络。

常规卷积参数量：

$$K \times K \times C \times C$$

深度可分离卷积加 1×1 卷积参数量：

$$K \times K \times C + C \times C$$

4. 池化层

池化层用于降低特征图分辨率。

课件原话要点：池化层仅改变空间大小，不改变特征通道数量；池化层没有需要学习的参数。

常见池化：

- 最大值池化。
- 平均值池化。

池化层输出大小也可用：

$$W' = \frac{W - F + 2P}{S} + 1$$

5. 激活函数

激活函数作用：获得非线性映射。

常见激活函数：Sigmoid 函数、双曲正切函数（Tanh）、修正线性单元（ReLU）、带泄漏修正线性单元（Leaky ReLU）。

Sigmoid：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

ReLU：

$$y = \max(0, x)$$

课件要点：Sigmoid 函数在深层网络中不优先使用，因为饱和时梯度接近 0，更新很慢，容易产生梯度消失；修正线性单元训练更快，计算代价小，可缓解梯度消失问题。

6. Softmax 分类器与交叉熵损失

Softmax 分类器将输出节点的分数转换为概率值，常用于类别互斥的分类任务。

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

输出概率均为正，且和为 1。

交叉熵损失：

$$L_i = -\log P(Y = y_i | X = x_i)$$

独热编码 形式：

$$L_i = -\sum_j y_j \log p_j$$

背诵句：Softmax 分类器通常用于分类网络的最后一层，得到各类别概率；预测概率输入交叉熵损失函数。

7. 典型卷积神经网络

AlexNet（经典图像分类网络）

课件原话式特点：AlexNet 是 8 层卷积神经网络，在 ImageNet 2012 中取得突破；使用分组卷积将特征通道分配到两个图形处理器（GPU）上。

结构简化：5 个卷积层 + 3 个全连接层。

第一层例子：输入，卷积核，步长=4，填充=0，输出通道 96。

输出空间大小：

$$W' = \frac{227 - 11 + 2 \times 0}{4} + 1 = 55$$

输出体积：

$$55 \times 55 \times 96$$

参数量：

$$11 \times 11 \times 3 \times 96 = 34848$$

课件要点：AlexNet 中参数主要分布在全连接层，卷积层参数相对较少。

VGG（经典图像分类网络）

VGG 特点：小卷积核、更深的网络；全部卷积层采用 卷积；常见 VGG16 和 VGG19。

为什么使用小卷积核：三个 3×3 卷积层堆叠具有与一个 7×7 卷积层相同的有效感受野，但网络更深、非线性更多、参数更少。

参数对比：

$$3 \times (3^2 C^2) \quad \text{vs.} \quad 7^2 C^2$$

即：

$$27C^2 \quad \text{vs.} \quad 49C^2$$

GoogleNet（经典图像分类网络）

GoogleNet 是 22 层深网络，使用 Inception 模块增加网络宽度，提高多尺度特征表达能力。

Inception 模块思想：并行使用多个感受野大小的卷积，例如 1×1 、 3×3 、 5×5 ，以及池化操作，最后在通道维度拼接。

改进：使用 瓶颈卷积进行维度降低，降低计算复杂度。

另一个特点：使用全局平均池化替代昂贵的全连接层。

ResNet（残差网络）

残差网络（ResNet）使用残差连接，使深度神经网络更容易训练，可将深度扩展到很深，例如 152 层。

残差块：

$$y = F(x) + x$$

背诵句：残差连接使网络学习残差映射，缓解深层网络训练困难和梯度传播问题。

MobileNet / ShuffleNet（轻量级网络）

这类网络常用于轻量级视觉任务。

MobileNet 常用深度可分离卷积减少参数量和计算量。

ShuffleNet 使用分组卷积和通道重排提升轻量级模型效率。

九、基于深度学习的目标检测与图像分割（第 13 讲、第 14 讲）

1. 深度学习目标检测任务

单目标检测可看作分类与定位的结合：一部分输出类别分数，一部分输出边界框坐标。

总损失：

$$L = L_{cls} + L_{box}$$

多目标检测难点：每张图像包含物体个数不同，无法通过预设固定个数输出节点直接预测所有目标。

2. 滑动窗口与区域提议

滑动窗口：对图像中不同位置、尺度和长宽比的窗口分别输入卷积神经网络，判断是否为目标。

问题：需要对巨大数量的位置、尺度、长宽比应用卷积神经网络，计算量非常大。

区域提议：寻找可能包含目标的块状图像区域，例如选择性搜索（Selective Search）可在中央处理器（CPU）上产生约 2000 个候选区域。

3. R-CNN 系列

R-CNN

流程：区域提议 → 缩放到固定大小 → 卷积神经网络特征提取 → 支持向量机分类 → 边界框回归。

问题：每张图像约 2000 个候选区域都要独立做卷积神经网络前向传播，非常慢；大量重叠区域存在重复计算。

Fast R-CNN

核心思路：先将整幅图像输入卷积神经网络提取特征，再在卷积特征图上裁剪每个候选区域的特征。

使用感兴趣区域池化（ROI Pool）将任意大小感兴趣区域（ROI）调整为固定大小特征表示。

问题：区域提议仍由选择性搜索等方法在中央处理器上计算，耗时较大；感兴趣区域池化有取整，可能导致空间错位。

感兴趣区域对齐（ROI Align）：不再取整，通过双线性插值采样，保持空间对齐关系。

Faster R-CNN

核心思路：让卷积神经网络产生区域提议，使用区域提议网络（RPN）从特征图直接预测候选框。

区域提议网络（RPN）：在特征图每个位置设置不同尺度和比例的锚框，预测：

1. 锚框是否为目标。
2. 从锚框到真实框的坐标修正量。

Faster R-CNN 是两阶段检测器：

1. 获得区域提议。
2. 对每个区域进行分类和边界框回归。

联合训练 4 个损失：

1. 区域提议网络判断锚框是否为目标。
2. 区域提议网络回归边界框坐标。
3. 最终目标类别分类分数。
4. 最终边界框坐标。

4. YOLO / SSD / RetinaNet

单阶段检测器：YOLO、SSD、RetinaNet。

特点：不显式产生候选区域，而是在密集位置上直接预测类别和边界框，速度快，适合实时检测。

YOLO 思路：

- 将图像划分为网格。
- 每个网格单元对多个基础框回归位置偏移和置信度。
- 同时预测类别分数。

对比：

R-CNN 系列与单阶段检测器对比：

- R-CNN：两阶段；每个候选区域单独进行卷积神经网络计算，速度慢。
- Fast R-CNN：两阶段；整图提取卷积特征，使用感兴趣区域池化，提高速度。
- Faster R-CNN：两阶段；区域提议网络生成候选区域，精度高但速度相对较慢。
- YOLO/SSD：单阶段；直接密集预测，速度快，适合实时检测。

5. 语义分割

语义分割：预测每个像素的类别。

与分类区别：分类只有图像级标签；语义分割需要输出与图像空间对应的像素级类别图。

6. FCN

全卷积网络（FCN）。

核心思想：将分类网络中的全连接层替换为卷积层，使网络可接受任意大小输入，并输出空间化的类别得分图，再通过上采样恢复到原图大小。

流程：

Input→Conv/Pool→Score Map→Upsample→Pixel Prediction

局限：分割结果不够精细，空间细节容易丢失。

7. 反卷积 / 转置卷积

反卷积用于上采样特征图，也称为转置卷积。

课件原话式理解：步长卷积可看作可学习的下采样；转置卷积可看作可学习的上采样。

普通步长卷积：滤波器在输入上移动若干像素，对应输出一个像素。

转置卷积：滤波器在输出上移动若干像素，每个输入值对输出区域进行加权贡献，重叠位置求和。

8. U-Net

U-Net 结构：

- 编码器：使用卷积和池化提取特征。
- 解码器：使用反卷积恢复分辨率。
- 跳跃连接：连接编码器和解码器中对应尺度的特征。

跳跃连接作用：改善梯度反向传播，并将高分辨率细节传递给解码器，使分割边界更精细。

9. DeepLab 与 HRNet

DeepLab: 使用空洞卷积得到高分辨率、大感受野特征；使用空洞空间金字塔池化（ASPP）中的多个并行分支和不同空洞率获得多尺度特征。

高分辨率网络（HRNet）: 始终保持高分辨率特征图，以防空间细节丢失；在不同尺度上进行卷积并融合多尺度特征。

10. Mask R-CNN

Mask R-CNN 从 Faster R-CNN 扩展而来。

课件原话式总结：在 Faster R-CNN 检测结果基础上，增加一个小的掩码网络，对每个感兴趣区域预测一个二值掩码。

输出包括：

- 分类分数。
- 边界框坐标。
- 掩码预测。

Mask R-CNN 可用于实例分割，也可用于姿态估计。

十、预训练、迁移学习与视觉基础模型（第 14 讲、第 15 讲）

1. 迁移学习

迁移学习背景：ImageNet 数据集上的成功依赖大量标注数据，但实际应用中通常只有小数据集。解决方法是将大数据集上学到的知识迁移到具体任务。

课件原话式总结：将大数据集上学习到的知识迁移到给定任务。

为什么可迁移：浅层网络学习的是通用低层特征，例如边缘滤波器；深层网络学习的是与具体物体相关的高层语义特征。

微调策略：

微调策略：

- 数据很少、数据集相似：只微调顶层线性分类器。
- 数据很少、数据集差异大：比较困难，尝试数据增强或收集更多数据。
- 数据较多、数据集相似：微调少数几层。
- 数据较多、数据集差异大：微调更多层。

课件建议：微调时使用较低学习率，原学习率的 1/10 是较好起点。

2. 视觉 Transformer 模型（Vision Transformer）

视觉 Transformer 模型使用 Transformer 结构代替卷积来捕获长距离特征关系。

基本步骤：

1. 将图像划分为图像块（patch）。
2. 从各个图像块中提取特征，称为图像块嵌入。
3. 使用多头自注意力机制学习所有图像块之间的全局依赖关系。

优点：

- 能够捕获长距离特征关系。
- 在大规模数据训练时性能较高。

缺点：

- 计算代价高，尤其是图像较大、图像块尺寸较小时。
- 模型大，因为使用大量多层感知机层。
- 图像块嵌入可能导致细节丢失。

3. 自监督学习

自监督学习通过借口任务在没有人工标签的条件下学习特征，并使学习到的特征可迁移到下游任务。

课件原话式定义：自监督学习方法通过解决借口任务来学习对下游任务有用的特征；这些借口任务的标签由数据自动生成。

自监督学习与生成模型区别：二者都试图从无人工标签数据中学习；生成学习目标是建模数据分布 $P_{data}(x)$ ，例如生成真实图像；自监督学习更强调学习可迁移特征。

常见自监督任务：

- 旋转角度分类。
- 图像块顺序分类，也称拼图任务。
- 图像重建。
- 掩码重建。
- 对比学习。

4. 旋转预测

旋转预测任务：预测图像旋转角度。正确识别旋转角度需要模型理解图像内容和结构。

流程：

1. 第一阶段：在借口任务上训练网络，不需要人工标签。
2. 第二阶段：将学到的特征用于新任务，用更少标签训练分类器或微调。

5. 图像重建与 MAE

自编码器：从无标注数据中学习数据的低维表达。

结构：

$$x \rightarrow \text{Encoder} \rightarrow z \rightarrow \text{Decoder} \rightarrow \hat{x}$$

重建误差：

$$L = \|\hat{x} - x\|^2$$

掩码自编码器（MAE）。

课件原话式要点：

- 用于预训练大型 Transformer 模型。
- 采用不对称的编码器-解码器结构。
- 高掩码比例，例如，构成有意义的自监督任务。
- 在下游任务中的迁移性能可以超过有监督预训练。

6. 对比学习

对比学习目标：让查询样本与正样本更接近，与负样本更远。

InfoNCE 损失的常见理解：把查询样本与正样本的相似性作为正样本得分，把查询样本与多个负样本的相似性作为负样本得分；训练目标是提高正样本得分、降低负样本得分。考试一般按概念理解即可：查询样本与正样本应尽量近，查询样本与负样本应尽量远。

7. 视觉基础模型

基础模型定义：在海量数据和算力上，以宽泛任务训练得到的大模型，通常作为特定任务模型的起点。

课件原话式总结：基础模型通过在大规模预训练数据上获取通用特征，可以有效迁移到下游多种任务中，如图像分类、分割、图文对话等；可以减少下游任务的数据和标注需求，提升下游任务性能。

十一、计算题模板

1. 窗宽窗位计算

给定窗宽 W 、窗位 L ，显示范围：

$$\left[L - \frac{W}{2}, L + \frac{W}{2} \right]$$

例： $W = 500, L = 100$ 。

$$[100 - 250, 100 + 250] = [-150, 350]$$

2. 精确率与召回率计算

若实际目标数为 N_{gt} ，检测数为 N_{pred} ，匹配成功数为 TP ：

$$Precision = \frac{TP}{N_{pred}}$$

$$Recall = \frac{TP}{N_{gt}}$$

例：实际 50 个，检测 40 个，匹配 20 个。

$$Precision = \frac{20}{40} = 50\%$$

$$Recall = \frac{20}{50} = 40\%$$

3. 神经网络参数量计算

全连接层参数量：

$$N_p = n_{in} \times n_{out} + n_{out}$$

卷积层参数量：

$$N_p = K^2 C_{in} C_{out} + C_{out}$$

如果题目不计偏置，则去掉 $+ C_{out}$ 。

例：输入层 5 个节点，隐藏层 4 个节点，输出层 1 个节点，各层全连接并包含偏置。

输入到隐藏层：

$$5 \times 4 + 4 = 24$$

隐藏层到输出层：

$$4 \times 1 + 1 = 5$$

总参数：

$$24 + 5 = 29$$

4. 卷积层输出大小计算

公式：

$$W' = \frac{W - F + 2P}{S} + 1$$

二维图像分别计算宽和高。输出通道数等于卷积核个数。

例：AlexNet 第一层输入，卷积核，步长=4，填充=0，输出通道 96。

$$W' = \frac{227 - 11}{4} + 1 = 55$$

输出：

$$55 \times 55 \times 96$$

参数量不计偏置：

$$11 \times 11 \times 3 \times 96 = 34848$$

5. 方向梯度直方图特征维度计算

步骤：

1. 先算单元格数量。
2. 再算块数量。
3. 再算每个块的维度。
4. 最后相乘。

例：窗口，单元格为，块为 个单元格，每个单元格 9 维，块步长为 1 个单元格。

单元格数量：

$$\frac{64}{8} \times \frac{128}{8} = 8 \times 16$$

块数量：

$$(8 - 2 + 1) \times (16 - 2 + 1) = 7 \times 15$$

每个块的维度：

$$2 \times 2 \times 9 = 36$$

总维度：

$$7 \times 15 \times 36 = 3780$$

6. 本征矩阵与极线约束计算

题型：给定 T, R ，给定第一幅图点 A ，第二幅图点 B 含未知数，求 B 。

步骤：

1. 把点写成齐次坐标：

$$x_1 = \begin{bmatrix} u_1 \\ v_1 \\ 1 \end{bmatrix}, \quad x_2 = \begin{bmatrix} u_2 \\ v_2 \\ 1 \end{bmatrix}$$

2. 根据题目给出的叉乘矩阵定义，计算 $[T]_{\times}$ 。

3. 计算本征矩阵：

$$E = [T]_{\times} R$$

4. 代入极线约束：

$$x_2^T E x_1 = 0$$

5. 解未知数。

考试提醒：这一类题最容易错在叉乘矩阵符号。题目若已经给出 $a_{\times}$ 的形式，就按题目给的形式写，不要按自己记忆的标准形式改。

7. 三角测量计算

题型：给定两个相机投影矩阵 P_1, P_2 ，给定图像对应点 A, B ，求三维点 X 。

步骤：

1. 设三维点:

$$X = \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

2. 设图像点齐次形式:

$$A = (u_1 w_1, v_1 w_1, w_1)^T$$

$$B = (u_2 w_2, v_2 w_2, w_2)^T$$

3. 写投影方程:

$$A = P_1 X, \quad B = P_2 X$$

4. 展开得到含 x, y, z, w_1, w_2 的方程。
5. 利用第三行通常得到 w_1, w_2 与 z 的关系, 代入求解 x, y, z 。

十二、简答题可背模板

1. Canny 边缘检测步骤

Canny 边缘检测具有高信噪比、高定位精度、高连续性等优点。其实现步骤为:

1. 在 x 和 y 方向上分别进行高斯差分滤波。
2. 计算各像素处梯度的方向和幅值。
3. 根据梯度方向进行非最大值抑制, 使边缘变细。
4. 通过双阈值区分强边缘和弱边缘, 并将可通过弱边缘连接的强边缘进行连接。

2. 全景图拼接步骤

1. 特征点检测, 可利用 Harris 角点检测实现。
2. 特征点描述, 可利用 SIFT 特征描述算子进行实现。
3. 特征匹配, 通过计算特征的相似性找到两幅图像中较为匹配的特征点。
4. 空间变换参数拟合, 可通过 RANSAC 进行实现。
5. 根据空间变换参数将两幅图像进行对齐和融合。

3. 四种典型卷积神经网络及特点

1. AlexNet: 8 层卷积神经网络, 使用分组卷积将特征通道分配到两个图形处理器上, 在 ImageNet 2012 中取得突破。
2. VGGNet: 有 16 或 19 层, 卷积层全部采用 3×3 卷积, 小卷积核堆叠使网络更深且非线性更强。
3. GoogleNet: 22 层深网络, 使用 Inception 模块增加网络宽度, 提高多尺度特征表达能力, 并使用全局平均池化减少全连接参数。
4. ResNet: 通过残差连接将网络深度扩展到很深, 使深度神经网络更容易训练。

4. R-CNN、Fast R-CNN、Faster R-CNN、YOLO 区别

R-CNN 先产生区域提议，再将每个区域缩放后分别输入卷积神经网络提取特征，最后用支持向量机分类和边界框回归，缺点是每张图像需要大量独立的卷积神经网络前向传播，速度很慢。

Fast R-CNN 先对整幅图像进行卷积神经网络特征提取，再在特征图上根据感兴趣区域提取固定大小特征，并同时进行分类和边界框回归，减少了重复卷积计算。

Faster R-CNN 使用区域提议网络在卷积神经网络特征图上直接产生区域提议，是两阶段检测器，精度较高但速度相对单阶段方法慢。

YOLO 将检测看作单阶段回归问题，直接在网格和预设框上预测类别和边界框，速度快，适合实时检测。

5. FCN、U-Net、Mask R-CNN 原理

全卷积网络将分类网络中的全连接层替换为卷积层，输出低分辨率得分图，再通过上采样得到像素级分类结果。

U-Net 包含编码器和解码器，编码器提取特征，解码器恢复分辨率，并通过跳跃连接融合高分辨率细节，常用于医学图像分割。

Mask R-CNN 在 Faster R-CNN 的基础上增加掩码分支，对每个感兴趣区域预测二值掩码，可实现实例分割。

6. 迁移学习与自监督学习

迁移学习是将大数据集上学到的知识迁移到具体任务中。浅层特征通常更通用，例如边缘和纹理；深层特征更任务特异。因此小数据集可冻结前面层，只训练或微调后面层。

自监督学习通过自动生成标签的借口任务进行训练，例如旋转预测、拼图、图像重建、掩码重建和对比学习。其目标是在无人工标签条件下学习可迁移到下游任务的通用特征。

十三、选择题与填空题易错点

1. 中值滤波是非线性滤波器，适合处理椒盐噪声，并且相对能保留边缘。
2. Harris 中两个特征值都大时是角点；一个大一个小是边缘；两个都小是平坦区域。
3. 二维仿射变换矩阵是 3×3 ，但要求解的参数是 6 个。
4. 投影变换矩阵是 3×3 ，通常有 8 个自由度。
5. Viola-Jones：基于积分图的类 Haar 特征 + AdaBoost。
6. 图像分割算法：图割、陈-维塞模型是分割算法；Dalal-Triggs、Viola-Jones 是检测算法。
7. 水平集模型比蛇形模型更适合处理拓扑结构变化。
8. 归一化相机中，图像与相机内部参数无关，仅取决于外部参数。
9. AlexNet 中参数主要集中在全连接层，不是卷积层。
10. 卷积神经网络浅层特征比深层特征更加通用，因此更适合迁移。
11. 开运算是先腐蚀后膨胀；闭运算是先膨胀后腐蚀。
12. Softmax 分类器用于互斥类别分类，将原始预测分数转换为和为 1 的概率。
13. 池化层没有可学习参数，只改变空间大小，不改变通道数。

14. 平均精度是在固定类别、固定交并比阈值下由精确率-召回率曲线得到；平均精度均值是多个平均精度的平均。
15. 霍夫变换中，图像空间一个点对应霍夫空间一条曲线；图像空间一条直线对应霍夫空间一个峰值点。

十四、最后背诵版

必背公式

$$P = K[R|T]$$

$$W' = \frac{W - F + 2P}{S} + 1$$

$$N_p = K^2 C_{in} C_{out} + C_{out}$$

$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

$$M = \sum_{x, y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

$$C = \det(M) - \alpha \text{trace}(M)^2$$

$$d = x \cos \theta + y \sin \theta$$

$$x_2^T E x_1 = 0, \quad E = [T]_{\times} R$$

$$x_2^T F x_1 = 0, \quad F = K^{-T} E K^{-1}$$

$$\text{IoU} = \frac{|B_p \cap B_g|}{|B_p \cup B_g|}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

必背算法

- Harris: 计算 M → 计算 C → 阈值筛选 → 非极大值抑制。
- Canny: 高斯差分滤波 → 梯度幅值和方向 → 非极大值抑制 → 双阈值和边缘连接。
- Hough: 边缘点投票 → 累加器找峰值 → 得到直线参数。
- 尺度不变特征变换: 尺度空间极值 → 主方向 → 窗口 → 维 → 归一化。
- RANSAC: 随机选点 → 拟合模型 → 找内点 → 用内点重拟合 → 保留内点最多模型。
- K-均值分割: 选 → 选像素特征 → 定义距离 → 交替更新中心和类别 → 后处理。
- 图割: 构图 → 设置邻接边和终端边 → 求最小割/最大流 → 得到前景背景。

- R-CNN 系列：R-CNN 慢，Fast R-CNN 共享卷积特征，Faster R-CNN 使用区域提议网络，YOLO 单阶段实时检测。